

Instituto de Matemática y Ciencias Afines – IMCA
MAESTRÍA EN MODELIZACIÓN MATEMÁTICA Y COMPUTACIONAL

Trabajo de Aplicación del curso Modelamiento Estadístico Predictivo

Predicción del nivel Satisfactorio en Lectura y Matemática:
un enfoque de clasificación aplicado a la Evaluación Muestral (EM) 2024

Autores:

Nombre y apellidos – Nombre y apellidos

Profesor:

Alex de la Cruz H.

Julio de 2026

Índice

1. Introducción	2
2. Metodología	2
2.1. Fuentes de datos y cruce	2
2.2. Variables objetivo	3
2.3. Selección de variables predictoras	3
2.4. Tratamiento de datos faltantes	3
2.5. Estrategia de muestreo	3
2.6. División entrenamiento / prueba y modelos	3
2.7. Métricas de evaluación	4
2.8. Software	4
3. Resultados	5
3.1. Descripción general de la base de datos	5
3.2. Análisis exploratorio	5
3.3. Preprocesamiento	5
3.4. Entrenamiento y validación: hiperparámetros seleccionados	5
3.5. Tabla comparativa de desempeño	5
3.6. Identificación y justificación del modelo seleccionado	7
3.7. Importancia de variables	8
3.8. Limitaciones observadas	8
4. Comentarios finales	10
Referencias	11
A. Anexos	11
A.1. Diccionario de escalas compuestas más relevantes	11
A.2. Llaves oficiales de cruce (según nota técnica de la base de datos)	12

1. Introducción

La Evaluación Muestral (EM) 2024, aplicada por el Ministerio de Educación del Perú (MINEDU–UMC), mide el logro de aprendizaje de estudiantes de sexto grado de primaria en dos competencias fundamentales: **Lectura** y **Matemática**, clasificando a cada estudiante en uno de cuatro niveles de desempeño (Previo al inicio, En inicio, En proceso y Satisfactorio). Identificar qué factores sociodemográficos, familiares y socioemocionales se asocian con alcanzar el nivel Satisfactorio resulta clave para focalizar políticas de refuerzo educativo de manera temprana, antes de que se apliquen evaluaciones estandarizadas de cierre de año.

La base de datos utilizada integra tres fuentes oficiales de la EM 2024 para sexto grado de primaria, unidas mediante la llave `ID_estudiante` (según las llaves de cruce documentadas por MINEDU–UMC): (i) los resultados de la evaluación (105,242 estudiantes a nivel nacional), (ii) el cuestionario aplicado al propio estudiante, y (iii) el cuestionario aplicado a la familia. De estos dos últimos se incorporan las 40 escalas psicométricas ya construidas por MINEDU–UMC (índices tipo Rasch/TRI) que resumen dimensiones como motivación, ansiedad matemática, clima escolar, violencia percibida e involucramiento parental, además de ocho variables sociodemográficas de la institución educativa y del estudiante.

El **objetivo** de este trabajo es construir y comparar dos modelos de clasificación binaria independientes –uno para Lectura y otro para Matemática– que predigan si un estudiante alcanza el nivel Satisfactorio en cada competencia, a partir de 49 variables predictoras sociodemográficas y socioemocionales, evaluando siete algoritmos de clasificación bajo un mismo esquema de validación cruzada.

Contar con un modelo predictivo confiable permite a las autoridades educativas anticipar, incluso antes de la evaluación, qué perfiles de estudiantes tienen menor probabilidad de alcanzar el nivel esperado, y así dirigir recursos de acompañamiento pedagógico –y no solo económicos o de infraestructura– de forma más eficiente.

2. Metodología

2.1. Fuentes de datos y cruce

Se integran tres bases oficiales de la EM 2024 (MINEDU–UMC): resultados de evaluación, cuestionario al estudiante y cuestionario a la familia. Siguiendo la nota técnica que acompaña la base de datos, la llave de cruce entre resultados y ambos cuestionarios es `ID_estudiante` (las llaves para cuestionarios de docente y director, `cod_mod7` + `anexo` [+ `ID_seccion`], no se emplean por no contar con esos archivos). El cruce alcanza una cobertura de 97.3 % con el cuestionario al estudiante y 91.1 % con el de familia sobre el universo de resultados; se optó por una unión (*left join*) desde la base de resultados, preservando el universo completo y añadiendo indicadores binarios de no-respuesta a cada cuestionario como predictores propios, en lugar de

descartar a los estudiantes cuyas familias no respondieron.

2.2. Variables objetivo

Se definen dos variables respuesta binarias, modeladas de forma **independiente**:

$$Y_{lectura} = \mathbb{I}\{grupo_L = \text{Satisfactorio}\}, \quad Y_{matematica} = \mathbb{I}\{grupo_M = \text{Satisfactorio}\}$$

2.3. Selección de variables predictoras

Se seleccionan 49 variables: ocho sociodemográficas (área, gestión y característica de la IE, sexo, lengua materna, índice y nivel socioeconómico, departamento), 26 escalas compuestas del cuestionario al estudiante y 14 del cuestionario a la familia, más dos indicadores de no-respuesta a cada cuestionario. Se excluyen deliberadamente `medida500_L/medida500_M` (la medida continua de la cual se deriva determinísticamente el nivel de logro) por constituir fuga de información. Se descartan asimismo los ~ 170 ítems crudos de cada cuestionario, dado que las 40 escalas compuestas ya los resumen psicométricamente; incluir ambos simultáneamente sería redundante y elevaría innecesariamente la dimensionalidad.

2.4. Tratamiento de datos faltantes

La variable `ise` presentaba 18,186 valores (17.3 %) codificados como texto `"#NULL!"`; se recodificaron como faltantes reales y la variable se imputó con la mediana (`nse` con la moda), dejando una variable indicadora de imputación. Las 40 escalas compuestas, con missing entre 2 % y 24 % según la variable (máximo en `FAM6PGEN_ACOSVIC`, acoso escolar), se imputaron con su propia mediana. Se excluyen del análisis los 4,296 estudiantes sin nivel de logro válido en al menos una competencia.

2.5. Estrategia de muestreo

Por viabilidad computacional al comparar siete algoritmos con validación cruzada –en particular por el costo cuadrático/cúbico de SVM respecto al número de observaciones– se trabaja sobre una submuestra aleatoria estratificada de 15,002 estudiantes, extraída del universo de 100,946 con nivel de logro válido. Esta decisión se documenta como limitación en la sección correspondiente.

2.6. División entrenamiento / prueba y modelos

Para cada variable respuesta se realiza una partición aleatoria estratificada 70/30. Se ajustan siete modelos por separado para Lectura y Matemática: regresión **logística** y **probit** (enlaces lineales de referencia); **Lasso**, **Ridge** y **Elastic Net** (regularización L1/L2/combinada

vía `glmnet`); **SVM** con kernel radial; y **Random Forest** (300 árboles). Todos se entrenan con validación cruzada de $k = 5$ folds maximizando el AUC-ROC promedio, vía `caret::train()`.

2.7. Métricas de evaluación

Sobre el conjunto de prueba se reportan exactitud, sensibilidad, especificidad, F1-score y AUC-ROC, dado el desbalance de clases presente en ambas variables respuesta (23.5 % Satisfactorio en Lectura, 14.7 % en Matemática).

2.8. Software

R, paquetes `caret`, `glmnet`, `e1071`, `kernlab`, `randomForest`, `pROC` y `tidyverse`.

3. Resultados

3.1. Descripción general de la base de datos

La base de resultados contiene 105,242 estudiantes a nivel nacional. Tras excluir registros sin nivel de logro válido en alguna competencia quedan 100,946 estudiantes, de los cuales se extrae la submuestra de trabajo de 15,002 casos. En esta submuestra, el 23.45 % de los estudiantes alcanza el nivel Satisfactorio en Lectura y el 14.72 % en Matemática –un desbalance de clases relevante que se retoma en la interpretación de resultados.

3.2. Análisis exploratorio

Se observa un gradiente socioeconómico claro: la proporción de estudiantes que alcanza el nivel Satisfactorio crece de forma sostenida del nivel socioeconómico bajo al alto, tanto en Lectura como en Matemática. A nivel de las escalas socioemocionales, variables como la ansiedad ante la matemática y la motivación hacia la matemática muestran diferencias visibles en su distribución entre quienes alcanzan el nivel Satisfactorio y quienes no, particularmente para la competencia de Matemática.

3.3. Preprocesamiento

Las variables categóricas se codifican como variables *dummy* dentro de `caret::train()` para los modelos que lo requieren (`glmnet`, `svmRadial`); las variables numéricas se centran y escalan únicamente para SVM. Los modelos basados en árboles y los GLM no requieren estandarización.

3.4. Entrenamiento y validación: hiperparámetros seleccionados

La Tabla 1 resume los hiperparámetros óptimos seleccionados por validación cruzada para cada modelo y competencia.

Modelo	Hiperparámetro	Lectura	Matemática
Lasso	λ	0.0004	0.0007
Ridge	λ	0.0078	0.0078
Elastic Net	α / λ	0.5 / 0.0008	0.9 / 0.0008
SVM radial	σ / C	0.0074 / 0.50	0.0074 / 0.25
Random Forest	mtry	27	2

Cuadro 1: Hiperparámetros óptimos seleccionados por validación cruzada ($k = 5$)

3.5. Tabla comparativa de desempeño

Las Tablas 2 y 3 presentan las métricas de desempeño de los siete modelos sobre el conjunto de prueba, para Lectura y Matemática respectivamente.

Modelo	Accuracy	Sensibilidad	Especificidad	F1	AUC
Probit	0.806	0.396	0.931	0.489	0.826
Logit	0.806	0.405	0.929	0.494	0.826
Lasso	0.806	0.397	0.931	0.490	0.826
Elastic Net	0.806	0.397	0.932	0.490	0.826
Ridge	0.805	0.369	0.938	0.470	0.823
Random Forest	0.797	0.275	0.957	0.388	0.804
SVM	—	—	—	—	sin convergencia*

Cuadro 2: Comparación de modelos — Lectura (conjunto de prueba, $n \approx 4,500$)

Modelo	Accuracy	Sensibilidad	Especificidad	F1	AUC
Probit	0.863	0.218	0.974	0.319	0.833
Logit	0.863	0.237	0.971	0.338	0.832
Lasso	0.863	0.221	0.973	0.321	0.832
Elastic Net	0.862	0.218	0.974	0.318	0.832
Ridge	0.862	0.201	0.977	0.301	0.829
Random Forest	0.853	0.003	1.000	0.006	0.799
SVM	0.863	0.208	0.976	0.309	0.798

Cuadro 3: Comparación de modelos — Matemática (conjunto de prueba, $n \approx 4,500$)

*Para Lectura, el modelo SVM no produjo predicciones de clase estables sobre el conjunto de prueba con los hiperparámetros seleccionados por validación cruzada, por lo que sus métricas no son reportables; se documenta como limitación.




Figura 1: Comparación de AUC entre los modelos evaluables, Lectura vs. Matemática




Figura 2: Curvas ROC de los modelos con predicción estable — Lectura

3.6. Identificación y justificación del modelo seleccionado

Considerando el AUC como criterio principal –por ser robusto al desbalance de clases– y el balance entre sensibilidad y especificidad, se selecciona la **regresión logística** como modelo final para ambas competencias: obtiene un desempeño estadísticamente equivalente al de los modelos regularizados (que no aportan mejora relevante, sugiriendo baja multicolinealidad efectiva tras la selección de variables), la mejor sensibilidad entre los modelos con AUC máximo, y coeficientes directamente interpretables para el análisis de política educativa. Random Forest y SVM, pese a




Figura 3: Curvas ROC de los siete modelos — Matemática

su mayor flexibilidad, no superan a los modelos lineales en este problema –y muestran sensibilidad muy baja o nula, afectados por el desbalance de clases.

3.7. Importancia de variables

Para **Lectura**, las variables con mayor peso en el modelo logístico son: pensamiento social positivo del estudiante, manifestaciones de violencia por parte de los estudiantes, disposición negativa del docente para la participación en clase, promoción del pensamiento social en el aula, y motivación controlada hacia la lectura en el tiempo libre. En el modelo de Random Forest destaca además el índice socioeconómico como cuarto predictor más relevante. En los modelos regularizados (Lasso), la lengua materna (categoría "otra lengua originaria") y el hecho de no haber respondido el cuestionario del estudiante emergen como los predictores de mayor magnitud, junto con variación relevante por departamento (Loreto, Tumbes, Tacna).

Para **Matemática**, el patrón es más específico al dominio: la **ansiedad ante la matemática** y la **motivación hacia la matemática** son, de forma consistente entre el modelo logístico y Random Forest, los predictores más importantes, seguidos por el gusto por la matemática percibido por la familia y el pensamiento social positivo del estudiante. Este resultado es coherente con la literatura de psicología educativa sobre ansiedad matemática como barrera específica de aprendizaje, distinta de los determinantes más generales de Lectura.

3.8. Limitaciones observadas

- El **desbalance de clases** (23.5 % / 14.7 % Satisfactorio) limita la sensibilidad de Random Forest y, en Lectura, impidió que SVM produjera predicciones estables; técnicas de balanceo o ajuste del umbral de decisión podrían mejorar estos modelos.




Figura 4: Importancia de variables por modelo — Lectura

- El uso de una **submuestra de 15,002** estudiantes (de 100,946 disponibles) por viabilidad computacional limita la potencia estadística respecto de usar el universo completo.
- El AUC máximo alcanzado (≈ 0.83) indica que, incluso con 49 predictores incluyendo escalas socioemocionales validadas, persiste una proporción relevante de variabilidad no explicada por estas variables –consistente con la naturaleza multicausal del aprendizaje.
- Los resultados corresponden a una evaluación de un año (2024) y son asociativos, no permiten inferir causalidad.




Figura 5: Importancia de variables por modelo — Matemática

4. Comentarios finales

El objetivo planteado –predecir si un estudiante alcanza el nivel Satisfactorio en Lectura y en Matemática mediante dos modelos binarios independientes– se cumple: la regresión logística ofrece el mejor balance entre desempeño e interpretabilidad para ambas competencias, con un AUC de prueba de 0.826 en Lectura y 0.832 en Matemática, superando de forma consistente a Random Forest y SVM bajo el desbalance de clases observado.

Un hallazgo sustantivo de este trabajo es que las **escalas socioemocionales y de clima escolar** –construidas a partir de los cuestionarios al estudiante y a la familia– añaden una capacidad predictiva considerable respecto de usar únicamente variables sociodemográficas: la ansiedad y motivación hacia la matemática, el clima de violencia percibida en el aula y el involucramiento parental resultan tan o más relevantes que el índice socioeconómico, que dominaba como predictor principal en una primera versión del análisis restringida a variables sociodemográficas. Esto sugiere que las intervenciones de refuerzo educativo no deberían limitarse a criterios puramente económicos, sino considerar también el bienestar socioemocional del estudiante y su relación con el aula.

El modelo seleccionado tiene utilidad práctica principalmente como herramienta de **priorización**, no de decisión individual: permite ordenar a los estudiantes según su probabilidad estimada de no alcanzar el nivel Satisfactorio, apoyando la focalización de recursos –tanto académicos como socioemocionales– hacia los perfiles de mayor riesgo.

Como principales limitaciones se señalan el desbalance de clases no corregido, el uso de una submuestra por razones computacionales, y la falta de las variables de los cuestionarios a docentes y directores (no disponibles para este trabajo), que podrían capturar el efecto del aula y la institución educativa. Como líneas futuras se propone: (i) aplicar técnicas de balanceo de clases (SMOTE, ponderación por costos) y optimización del umbral de decisión, especialmente para resolver la inestabilidad de SVM en Lectura; (ii) incorporar los cuestionarios de docente y director mediante sus llaves oficiales de cruce; y (iii) explorar modelos multinivel que consideren el efecto de la institución educativa sobre el desempeño de sus estudiantes.

Referencias

- Ministerio de Educación del Perú – UMC. (2024). *Evaluación Muestral (EM) 2024, Sexto Grado de Primaria*. Bases de datos innominadas: resultados, cuestionario al estudiante y cuestionario a la familia.
- Kuhn, M. (2008). Building predictive models in R using the caret package. *Journal of Statistical Software*, 28(5), 1–26.
- Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297.

A. Anexos

A.1. Diccionario de escalas compuestas más relevantes

Código	Descripción
EST6PCCSS_PENSOCPO	Pensamiento social del estudiante – Positivo
EST6PGEN_VIOLEST	Manifestaciones de violencia por parte de los estudiantes
EST6PGEN_OPARDOCN	Disposición negativa del docente para participación en clase
EST6PMAT_ANSIE	Ansiedad ante la matemática
EST6PMAT_MOTMAT	Motivación hacia la Matemática
FAM6PMAT_PGUSTO	Gusto por la matemática (percepción de la familia)
FAM6PGEN_INVGENAC	Involucramiento parental general – Realizar actividades
FAM6PGEN_BIENEST	Malestar socioafectivo del estudiante

Cuadro 4: Diccionario — variables compuestas con mayor importancia predictiva

A.2. Llaves oficiales de cruce (según nota técnica de la base de datos)

- Resultados ↔ Cuestionario a padres de familia y Cuestionario al estudiante: llave `ID_estudiante`.
- Resultados ↔ Cuestionario a docentes: llaves `cod_mod7` + `anexo` + `ID_seccion` (no disponible para este trabajo).
- Resultados ↔ Cuestionario al director: llaves `cod_mod7` + `anexo` (no disponible para este trabajo).